


# Cours Neural-fidélité.

Dans ce cours on cherche à comprendre comment sont propagées les incertitudes dans les simulations numériques.

## I - Principe:

### 1.1 Simulation numérique:

On définit le simulateur par une fonction  $f$  qui à partir d'entrées  $x \in \mathbb{R}^n$  permet de modéliser un phénomène et qui permet d'avoir un résultat  $y \in \mathbb{R}$ .



$f$  peut par exemple modéliser un écoulement.

### 1.2 Simulateurs:

Le problème est que souvent  $f$  est très coûteux.

On suppose qu'on a:

→ un simulateur haute fidélité  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ .

→ un ensemble de simulateurs basse fidélité  $\{g_\ell: \mathbb{R}^d \rightarrow \mathbb{R}\}_{\ell=1, \dots, m}$   
(ex: réseau de neurones, différents types de maillage).


On va alors chercher à comprendre comment sont propagées les incertitudes dans ces simulateurs.

## II - Incertitudes:

On se place maintenant dans un contexte probabiliste.

### 2.1 Incertitude dans le simulateur:

- ↳ On modélise les paramètres incertains par des variables aléatoires  $X = (X_1, \dots, X_d)$
- On va s'intéresser à  $Y = f(X)$  qui représente l'incertitude sur la sortie.



### 2.2 Estimation statistique:

On veut estimer un paramètre  $\theta$  d'une variable aléatoire  $Y$  définie sur  $(\Omega, \mathcal{F}, P)$

1) n. échantillon:

Un n. échantillon de  $Y$  est un n-uplet  $(Y_1, \dots, Y_n)$  de variable aléatoire indépendantes et i.i.d de même loi que  $Y$ .

2) Echantillon de Monte-Carlo:

Soit  $(X_1, \dots, X_n)$  un n. échantillon de  $X$  alors  $(Y_1, \dots, Y_n)$  avec  $Y_i = f(X_i)$  est un échantillon de  $Y$ .

3) Estimateur: Soit  $(Y_1, \dots, Y_n)$  un n. échantillon de  $Y$  et  $\hat{\nu}_n: \mathbb{R}^n \rightarrow \mathbb{R}$  alors

$\hat{\theta}_n = \hat{\nu}_n(Y_1, \dots, Y_n)$  est un estimateur de  $\theta$ .

$\theta$  est un paramètre inconnu.

4) Estimation: Soit  $(y_1, \dots, y_n)$  une réalisation de  $(Y_1, \dots, Y_n)$  alors  $\hat{\theta}_n(y_1, \dots, y_n)$  est une estimation de  $\theta$ .

## 2.3 Qualité d'un estimateur:

1) Biais d'un estimateur:

$$\text{Bias}(\hat{\theta}_n, \theta) = E[\hat{\theta}_n - \theta] = E[\hat{\theta}_n] - \theta$$

→ si  $\text{Bias}(\hat{\theta}_n, \theta) \neq 0 \Rightarrow \hat{\theta}_n$  estimateur biaisé de  $\theta$ .

→ sinon il est sans biais.

2) Erreur quadratique moyenne:

3) Décomposition biais-variance:

$$\text{EQM}(\hat{\theta}_n, \theta) = \underbrace{\text{Bias}(\hat{\theta}_n, \theta)^2}_{\text{mesure la capacité}} + \underbrace{V[\hat{\theta}_n]}_{\text{mesure la sensibilité}}$$

$$\bullet \text{EQM}(\hat{\theta}_n, \theta) = E[(\hat{\theta}_n - \theta)^2]$$

$$\bullet \text{REQM}(\hat{\theta}_n, \theta) = \sqrt{\text{EQM}(\hat{\theta}_n, \theta)}$$

du modèle à capturer la relation du modèle aux  
entre les entrées et la sortie fluctuations des données.

3) Estimation de l'espérance:

Soit  $(Y_1, \dots, Y_n)$  un n. échantillon de  $Y$ .

Moyenne empirique:  $\bar{Y}_n = \bar{\mu}_n(Y_1, \dots, Y_n) = \frac{1}{n} \sum_{i=1}^n Y_i$

$$\bullet E[\bar{Y}_n] = \mu \quad (\text{sans biais})$$

$$\bullet V[\bar{Y}_n] = \frac{\sigma^2}{n}$$

Question: Comment combiner les estimateurs?

### III. Méthodes avec variable de contrôle:

#### 3.1 Une variable de contrôle:

Méthode utilisée pour améliorer l'efficacité et la précision des simulations de Monte-Carlo.

On a  $Y$  la variable aléatoire dont on veut estimer l'espérance et  $Z$  une variable aléatoire auxiliaire (variable de contrôle) dont on connaît l'espérance  $\mu_Z$ .

Il faut que  $Y$  et  $Z$  soient corrélés.

Estimateur:  $Y_n^{cv}(\alpha) = \bar{Y}_n - \alpha(\bar{Z}_n - \mu_Z)$ .

On cherche la valeur de  $\alpha$  qui minimise  $V[Y_n^{cv}(\alpha)]$ .

Démo:  $V[Y_n^{cv}(\alpha)] = V[\bar{Y}_n] + \alpha^2 V[\bar{Z}_n] - 2\alpha C[\bar{Y}_n, \bar{Z}_n] = J(\alpha)$ .

$$J'(\alpha) = 2\alpha V[\bar{Z}_n] - 2C[\bar{Y}_n, \bar{Z}_n].$$

$$\hookrightarrow J'(\alpha) = 0 \Leftrightarrow \boxed{\alpha^* = \frac{C[\bar{Y}_n, \bar{Z}_n]}{V[\bar{Z}_n]}}$$

$$J(\alpha^*) = V[\bar{Y}_n] + \frac{C^2[\bar{Y}_n, \bar{Z}_n]}{V[\bar{Z}_n]} - 2 \times \frac{C^2[\bar{Y}_n, \bar{Z}_n]}{V[\bar{Z}_n]} < J(\alpha)$$

$\hookrightarrow$  on a diminué le biais

$$J(\alpha^*) = V[\bar{Y}_n] - \frac{C^2[\bar{Y}_n, \bar{Z}_n]}{V[\bar{Z}_n]}$$

$$\Rightarrow V[\bar{Y}_n^{cv}(\alpha^*)] = V[\bar{Y}_n] \times \left( 1 - \frac{C^2[\bar{Y}_n, \bar{Z}_n]}{V[\bar{Y}_n] V[\bar{Z}_n]} \right) \\ = (1 - \rho^2) V[\bar{Y}_n].$$

• paramètre optimal:  $\alpha^* = \frac{C[\bar{Y}_n, \bar{Z}_n]}{V[\bar{Z}_n]}$

• réduction de la variance:  $V[\bar{Y}_n^{cv}(\alpha^*)] = (1 - \rho^2) V[\bar{Y}_n]$ .

$\hookrightarrow$  on a bien réduit la variance par rapport à l'expression initiale.

#### 3.2. Plusieurs variable de contrôle:

On a maintenant  $m$  variables de contrôle  $z^1, \dots, z^m$ .

On s'intéresse à l'estimateur : 
$$\bar{y}_n^{\text{cv}}(\alpha) = \bar{y}_n - \sum_{k=1}^m \alpha_k (\bar{z}_n^k - \mu^k)$$
$$= \bar{y}_n - (\bar{z}_n - \mu_z)^T \alpha.$$

On cherche maintenant  $\alpha$  qui minimise  $V[\bar{y}_n^{\text{cv}}(\alpha)]$ .

$$V[\bar{y}_n^{\text{cv}}(\alpha)] = V[\bar{y}_n] + \alpha^T C[\bar{z}_n, \bar{z}_n] \alpha - 2 C[\bar{z}_n, \bar{y}_n]^T \alpha.$$

Démo:

$$\begin{aligned} V[\bar{y}_n^{\text{cv}}(\alpha)] &= \text{Var}[\bar{y}_n] - \text{Var}\left[\sum_{k=1}^m \alpha_k (\bar{z}_n^k - \mu^k)\right] \\ &= \text{---} + \text{Var}\left(\sum_{k=1}^m \alpha_k (\bar{z}_n^k - \mu^k)\right) - 2 \text{Cov}\left(\bar{y}_n, \sum_{k=1}^m \alpha_k (\bar{z}_n^k - \mu^k)\right) \\ &= \text{---} + \text{Var}\left(\sum_{k=1}^m \alpha_k \bar{z}_n^k\right) - 2 \text{Cov}\left(\bar{y}_n, \sum_{k=1}^m \alpha_k \bar{z}_n^k\right) \\ &= \text{---} + \sum_{k=1}^m \sum_{j=1}^m \alpha_k \alpha_j \text{Cov}(\bar{z}_n^k, \bar{z}_n^j) - 2 \sum_{k=1}^m \alpha_k \text{Cov}(\bar{y}_n, \bar{z}_n^k) \\ &= \text{---} + \alpha^T \text{Cov}(\bar{z}_n, \bar{z}_n) \alpha - 2 \alpha^T \text{Cov}(\bar{y}_n, \bar{z}_n). \end{aligned}$$

• Paramètre optimal:

$$\alpha^* = C[\bar{z}_n, \bar{z}_n]^{-1} C[\bar{z}_n, \bar{y}_n].$$

Démo: le minimum est atteint en  $\nabla_{\alpha} V[\bar{y}_n^{\text{cv}}(\alpha)] = 0$

$$\nabla_{\alpha} V[\bar{y}_n^{\text{cv}}(\alpha)] = C[\bar{z}_n, \bar{z}_n] \alpha + C[\bar{z}_n, \bar{z}_n]^T \alpha - 2 C[\bar{z}_n, \bar{y}_n]$$

$C[\bar{z}_n, \bar{z}_n]$  est symétrique donc:

$$\begin{cases} \nabla_{\alpha} V[\bar{y}_n^{\text{cv}}(\alpha)] = 0 \\ \Sigma \text{ inversible} \end{cases} \Rightarrow \begin{aligned} C[\bar{z}_n, \bar{z}_n] \alpha^* &= C[\bar{z}_n, \bar{y}_n] \\ \Rightarrow \alpha^* &= C[\bar{z}_n, \bar{z}_n]^{-1} C[\bar{z}_n, \bar{y}_n] \end{aligned}$$

• Réduction de la variance:

$$V[\bar{y}_n^{\text{cv}}(\alpha)] = V[\bar{y}_n] + \alpha^T C[\bar{z}_n, \bar{z}_n] \alpha - 2 C[\bar{z}_n, \bar{y}_n]^T \alpha.$$

$$V[\bar{y}_n^{\text{cv}}(\alpha^*)] = (1 - R^2) V[\bar{y}_n] \quad \text{avec} \quad R^2 = \frac{C[\bar{z}_n, \bar{y}_n]^T C[\bar{z}_n, \bar{z}_n]^{-1} C[\bar{z}_n, \bar{y}_n]}{V[\bar{y}_n]}.$$

Démo:

$$\begin{aligned} V[\bar{y}_n^{\text{cv}}(\alpha^*)] &= V[\bar{y}_n] + C[\bar{z}_n, \bar{z}_n]^{-1} C[\bar{z}_n, \bar{y}_n]^T C[\bar{z}_n, \bar{y}_n] C[\bar{z}_n, \bar{z}_n]^{-1} C[\bar{z}_n, \bar{y}_n] \\ &\quad - 2 C[\bar{z}_n, \bar{y}_n]^T C[\bar{z}_n, \bar{z}_n]^{-1} C[\bar{z}_n, \bar{y}_n]. \end{aligned}$$

#### IV - Couplage:

lien avec les modèles de haute/basse fidélité:

On pose  $Y = f(x)$  (le modèle de haute fidélité).  
 $Z^k = g_k(x)$  (le modèle de basse fidélité).

On a alors:  $C[\bar{Y}_n, \bar{Z}_n^k] = \frac{1}{n} C[Y, Z^k]$  et  $C[\bar{Z}_n^k, \bar{Z}_n^l] = \frac{1}{n} C[Z^k, Z^l]$ .

• Paramètre optimal + réduction de variance:

$$\bullet \alpha^* = C[Z, Z]^{-1} \cdot C[Z, Y].$$

$$\text{Corr}[X, X] = \text{Var}[X]^{-1/2} C[X, X] \text{Var}[X]^{-1/2}$$

$$\bullet R^2 = \frac{C[Z, Y]^T C[Z, Z]^{-1} C[Z, Y]}{\text{Var}[Y]} = \text{Corr}[Z, Y]^T \text{Corr}[Z, Z]^{-1} \text{Corr}[Z, Y].$$

$$(\text{Si } m=1 \text{ (une var de contrôle)}) : \alpha^* = \frac{C[Y, Z]}{\text{Var}[Z]} \quad \text{et} \quad R^2 = \frac{C[Y, Z]^2}{\text{Var}[Y] \text{Var}[Z]} = \text{Corr}[Y, Z]^2 = \rho^2.$$

#### II - Ajout de variable de contrôle :

inversion par bloc:

Soit  $H$  la matrice par bloc définie par:  $H = \begin{bmatrix} A & B \\ C & D \end{bmatrix}$ .  
Si  $A$  et  $H$  inversibles alors  $S = D - CA^{-1}B$  est inversible et:

$$R^{-1}, \begin{bmatrix} A^{-1} + A^{-1}BS^{-1}CA^{-1} & -A^{-1}BS^{-1} \\ -S^{-1}CA^{-1} & S^{-1} \end{bmatrix}.$$

• Théorème: Soit  $R_+ = \begin{bmatrix} R & u \\ u^T & 1 \end{bmatrix}$  et  $r = \begin{bmatrix} r \\ b \end{bmatrix}$  qui correspondent à l'ajout d'une variable  $z^{m+1}$ .

On suppose que  $R$  et  $R_+$  sont inversibles :

$$R_+ = R^2 + \frac{(b - u^T R^{-1} r)^2}{1 - u^T R^{-1} u} \gg R^2.$$

$$\text{et } R_+^2 = R^2 \Leftrightarrow b = u^T R^{-1} r.$$

Démonstration:

$$R = \text{Corr}[Z, Z]$$

$$u = \text{Corr}[Z, Z^{m+1}]$$

$$r = \text{Corr}[Y, Z^{m+1}]$$

$$R_+ = \text{Corr}[Z_+, Z_+]$$

$$r_+ = \text{Corr}[Y, Z_+]$$

$$R_+^{-2} = r_+^{-T} R_+^{-1} r_+^{-1}$$

$$= \underbrace{\begin{pmatrix} r & b \end{pmatrix}}_{(1 \times n)} \begin{pmatrix} R^{-1} + R^{-1}US^{-1}U^T R^{-1} & -R^{-1}US^{-1} \\ -S^{-1}U^T R^{-1} & S^{-1} \end{pmatrix}^T \begin{pmatrix} r \\ b \end{pmatrix}$$

$$= \begin{pmatrix} r(R^{-1} + R^{-1}US^{-1}U^T R^{-1}) - bS^{-1}U^T R^{-1} & -rR^{-1}US^{-1} + bS^{-1} \end{pmatrix} \begin{pmatrix} r \\ b \end{pmatrix}.$$

$$= (r(R^{-1} + R^{-1}US^{-1}U^T R^{-1}) - bS^{-1}U^T R^{-1})r + b(-rR^{-1}US^{-1} + bS^{-1}).$$

$$= r^T(R^{-1} + R^{-1}US^{-1}U^T R^{-1})r - bS^{-1}U^T R^{-1}r - brR^{-1}US^{-1} + b^2S^{-1}$$

$$= R^2 + r^T R^{-1}US^{-1}U^T R^{-1}r - r^T R^{-1}US^{-1}b - bS^{-1}U^T R^{-1}r + b^2S^{-1}$$

$$= R^2 + \beta^2 S^{-1} - 2b\beta S^{-1} + b^2 S^{-1}$$

$$= R^2 + (\beta^2 - 2b\beta + b^2)S^{-1}$$

$$= R^2 + (b - \beta)^2 S^{-1}$$

$$= R^2 + (b - u^T R^{-1} r)^2 S^{-1}$$

$R^+$  est inversible,  $R$  est symétrique définie positive :  $\forall v, v^T R v > 0$ .

$$v_+ = \begin{bmatrix} v \\ \beta \end{bmatrix}$$

$$[v^T \ \beta] \times \begin{bmatrix} R & u \\ u^T & 1 \end{bmatrix} \times \begin{bmatrix} v \\ \beta \end{bmatrix} = 1 - u^T R^{-1} u.$$

$$[v^T R + \beta u^T] v + (v^T u + \beta) \beta = 1 - u^T R^{-1} u$$

$$v^T R v + \beta u^T v + v^T u \beta + \beta^2 = 1 - u^T R^{-1} u$$

$$\left\{ \begin{array}{l} \beta \cdot 1 \\ v^T R v - u^T v - v^T u - 1 = 1 - u^T R^{-1} u \end{array} \right.$$

$$u^T R^{-1} R u + R^{-1} u - u^T R^{-1} u - u^T R u = -u^T R^{-1} u$$

$$u^T R^{-1} u - u^T R^{-1} u - u^T R^{-1} u = -u^T R^{-1} u.$$

$$v_+ \neq 0 \mid v_+^T R_+^{-1} v_+ > 0$$

## III - Coûts pour l'application à la simulation numérique :

1) Quand la méthode est-elle rentable ?

On a l'estimateur  $\bar{Y}_n^{\text{co}}(\alpha^*) = \bar{Y}_n - \alpha^*(\bar{Z}_n - \mu_Z)$ .

Coût de l'estimateur :

- Soit  $c_f(x)$  le coût (temps CPU) d'évaluer  $f(x)$  et  $c_f = \mathbb{E}[c_f(x)]$ .
- Soit  $c_g(x)$  le coût (temps CPU) d'évaluer  $g(x)$  et  $c_g = \mathbb{E}[c_g(x)] < c_f$ .

On note  $w = \frac{c_g}{c_f} > 1$ .

Le coût total moyen est  $c = n(c_f + c_g)$  et on note  $\tilde{n} = \frac{c}{c_f} = n(1+w)$ .  
(= nombre d'échantillons haute fidélité).

Variance de l'estimateur :

$$V[\bar{Y}_n^{\text{co}}(\alpha^*)] = V[\bar{Y}_n](1+w)(1-\rho^2)$$

Réduction de variance  $\Leftrightarrow \rho^2 > \frac{w}{1+w}$ .

2) Comment approximer  $\alpha^*$  ?

1) Estimateur indépendant à l'aide d'échantillons pilotes:

On a  $(X_1, \dots, X_p)$  un  $p$ -échantillon indépendant de  $(X_1, \dots, X_n)$ ,  $\tilde{Y}_i = f(\tilde{X}_i)$  et  $\tilde{Z}_i = g(\tilde{X}_i)$ .

Estimateur: 
$$\hat{\alpha}^* = \frac{\text{Cov}_p(Y_1, \dots, Y_p; Z_1, \dots, Z_p)}{\text{Var}_p(Z_1, \dots, Z_p)}.$$

$\hookrightarrow \bar{Y}_n^{CV}(\hat{\alpha}^*)$  non biaisé.

2) Estimateur avec les mêmes échantillons  $Y_n$  et  $Z_n$ :

$$\hat{\alpha}^* = \frac{\text{Cov}_n(Y_1, \dots, Y_n; Z_1, \dots, Z_n)}{\text{Var}_n(Z_1, \dots, Z_n)}.$$

$\hookrightarrow \bar{Y}_n^{CV}(\hat{\alpha}^*)$  est biaisé.

$\hookrightarrow$  Dans les 2 cas on a une détérioration de la réduction de la variance.